03. Mental Health Label 심층 분석

데이터셋의 핵심 도메인 컬럼인 `Mental_Health_Label`을 심층 분석합니다. 이 분석은 MindTune의 음악 심리 케어 기능의 근거가 됩니다.

핵심 질문:

- 각 Mental Health Label은 어떤 오디오 피처 프로파일을 가지는가?
- Depression, Anxiety, Bipolar 곡들은 피처 수준에서 유의미하게 구분되는가?
- 소수 라벨(PTSD 38곡, Depression 138곡)의 추천 다양성은 충분한가?
- 특정 라벨에 특정 장르가 편중되어 있는가?

In [ ]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy import stats
import warnings

warnings.filterwarnings('ignore')
plt.rcParams['font.size'] = 11
plt.rcParams['figure.figsize'] = (12, 6)
plt.rcParams['axes.unicode_minus'] = False
sns.set_style('whitegrid')

df = pd.read_csv('../data/Music_recommendation.csv')

AUDIO_FEATURES = ['danceability', 'energy', 'valence', 'tempo',
                  'acousticness', 'instrumentalness', 'speechiness',
                  'loudness', 'liveness']

print("=== Mental Health Label 분포 ===")
mh_counts = df['Mental_Health_Label'].value_counts()
print(mh_counts)
print(f"\n고유 라벨 수: {df['Mental_Health_Label'].nunique()}")
```

```
=== Mental Health Label 분포 ===
Mental_Health_Label
Normal/Unclassified     22145
Bipolar (Mania)          5016
Anxiety                  4922
Bipolar (Depression)      335
Depression                138
Autism                    114
Schizophrenia             109
PTSD                       38
Dementia                    8
OCD                         8
Name: count, dtype: int64

고유 라벨 수: 10
```

3.1 라벨 분포 시각화

In [ ]:
```
fig, axes = plt.subplots(1, 2, figsize=(16, 6))

# 막대 그래프 (로그 스케일)
colors_mh = plt.cm.Set3(np.linspace(0, 1, len(mh_counts)))
bars = axes[0].barh(mh_counts.index, mh_counts.values, color=colors_mh, edgecolo
axes[0].set_xscale('log')
axes[0].set_xlabel('Number of Tracks (log scale)')
axes[0].set_title('Mental Health Label Distribution (log scale)')
for bar, val in zip(bars, mh_counts.values):
    axes[0].text(val * 1.1, bar.get_y() + bar.get_height()/2,
                 f'{val:,} ({val/len(df)*100:.1f}%)', va='center', fontsize=9)

# 파이 차트 (Normal vs Non-Normal)
normal_count = mh_counts.get('Normal/Unclassified', 0)
non_normal_count = len(df) - normal_count
axes[1].pie([normal_count, non_normal_count],
            labels=['Normal/Unclassified', 'Mental Health Labels'],
            colors=['#95a5a6', '#e74c3c'], autopct='%1.1f%%', startangle=90,
            textprops={'fontsize': 12})
axes[1].set_title('Normal vs Mental Health Labeled')

plt.tight_layout()
plt.show()

print(f"\n불균형 비율: Normal 대비 가장 적은 라벨 = {mh_counts.min()}곡 "
      f"(1:{normal_count // mh_counts.min()})")
```

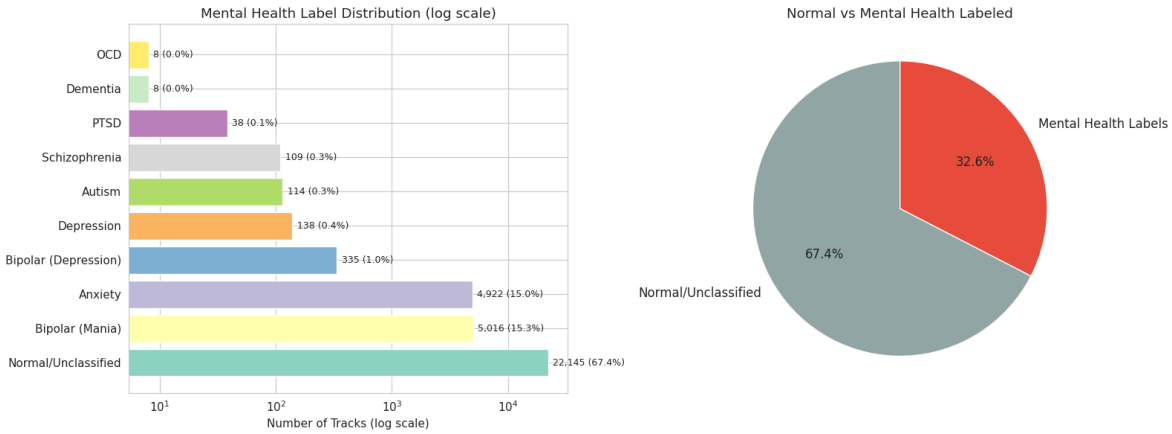


```
불균형 비율: Normal 대비 가장 적은 라벨 = 8곡 (1:2768)
```

3.2 라벨별 오디오 피처 프로파일

각 Mental Health Label의 평균 오디오 피처를 비교합니다.

In [ ]:
```
# 라벨별 피처 평균값 테이블
profile = df.groupby('Mental_Health_Label')[AUDIO_FEATURES].mean().round(3)
profile['count'] = df.groupby('Mental_Health_Label').size()
profile = profile.sort_values('count', ascending=False)
print("=== 라벨별 오디오 피처 평균 프로파일 ===")
profile
```

```
=== 라벨별 오디오 피처 평균 프로파일 ===
```

Out[ ]:

Mental_Health_Label	danceability	energy	valence	tempo	acousticness	instrumental
Normal/Unclassified	0.662	0.655	0.507	117.350	0.195	0
Bipolar (Mania)	0.704	0.826	0.820	122.322	0.141	0
Anxiety	0.589	0.819	0.247	136.592	0.066	0
Bipolar (Depression)	0.528	0.214	0.170	118.854	0.702	0
Depression	0.475	0.269	0.165	72.940	0.618	0
Autism	0.645	0.594	0.398	99.283	0.302	0
Schizophrenia	0.602	0.494	0.507	163.611	0.388	0
PTSD	0.488	0.657	0.192	103.545	0.214	0
Dementia	0.618	0.237	0.467	66.152	0.798	0
OCD	0.644	0.668	0.463	100.625	0.225	0

In [ ]:

```
# 레이더 차트: 주요 라벨의 피처 프로파일 비교
from matplotlib.patches import FancyBboxPatch

# 0~1 범위 피처만 사용 (레이더 차트에 적합)
radar_features = ['danceability', 'energy', 'valence', 'acousticness',
                  'instrumentalness', 'speechiness', 'liveness']
main_labels = ['Normal/Unclassified', 'Anxiety', 'Bipolar (Mania)',
               'Bipolar (Depression)', 'Depression', 'PTSD']
# 데이터에 존재하는 라벨만 필터
main_labels = [l for l in main_labels if l in df['Mental_Health_Label'].unique()

angles = np.linspace(0, 2 * np.pi, len(radar_features), endpoint=False).tolist()
angles += angles[:1]  # 닫기

fig, ax = plt.subplots(figsize=(10, 10), subplot_kw=dict(polar=True))
label_colors = ['#95a5a6', '#e74c3c', '#f39c12', '#3498db', '#2c3e50', '#8e44ad'

for idx, label in enumerate(main_labels):
    values = df[df['Mental_Health_Label'] == label][radar_features].mean().tolis
    values += values[:1]
    ax.plot(angles, values, 'o-', linewidth=2, label=label, color=label_colors[i
    ax.fill(angles, values, alpha=0.05, color=label_colors[idx])

ax.set_thetagrids(np.degrees(angles[:-1]), radar_features, fontsize=11)
ax.set_title('Audio Feature Profile by Mental Health Label', fontsize=14, y=1.08
ax.legend(loc='upper right', bbox_to_anchor=(1.35, 1.1), fontsize=10)
ax.set_ylim(0, 1)
plt.tight_layout()
plt.show()
```

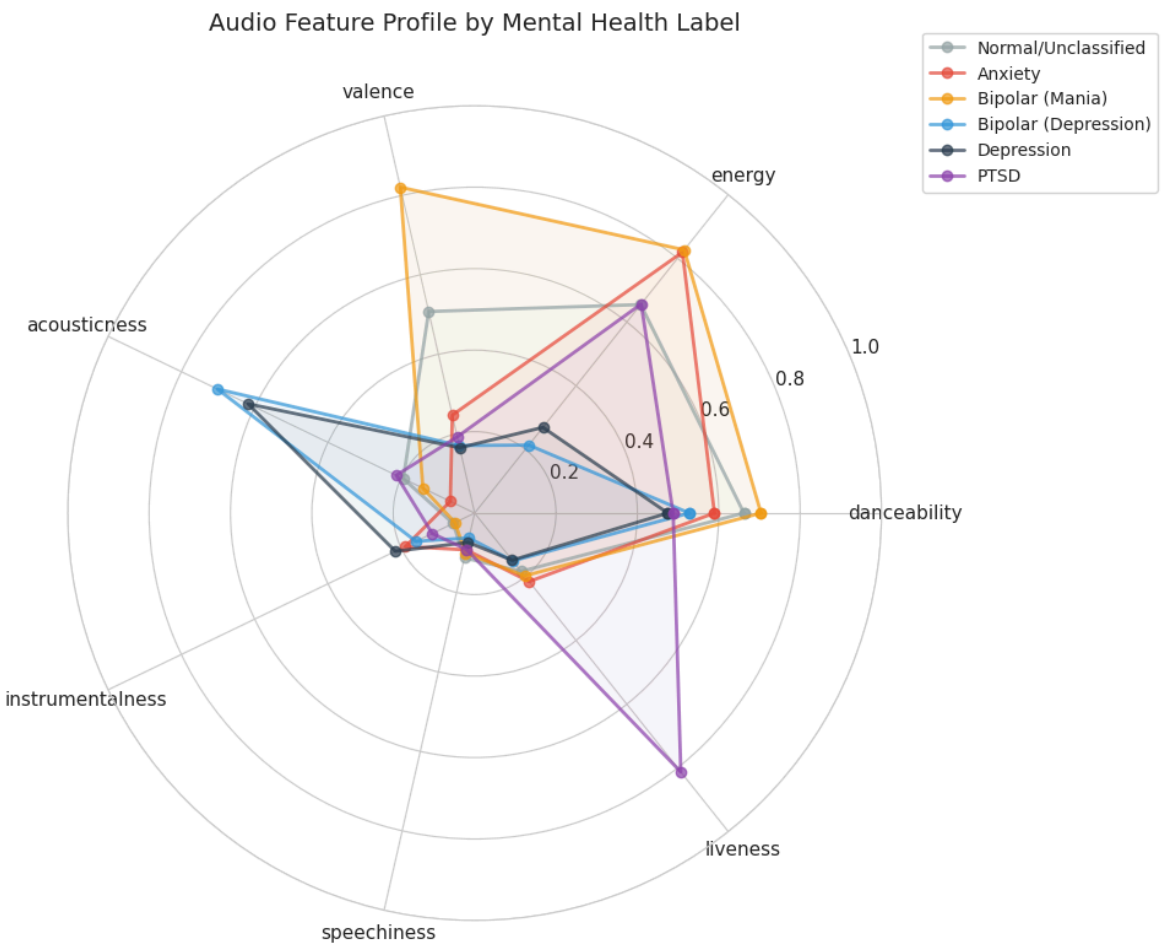

3.3 라벨별 주요 피처 분포 비교 (바이올린 플롯)

In [ ]:
```
key_features = ['valence', 'energy', 'tempo', 'acousticness']
fig, axes = plt.subplots(2, 2, figsize=(16, 12))

for idx, feat in enumerate(key_features):
    ax = axes[idx // 2, idx % 2]
    # 주요 라벨만 필터 (곡 수가 너무 적은 라벨은 시각화에 부적합)
    plot_df = df[df['Mental_Health_Label'].isin(main_labels)]
    sns.violinplot(data=plot_df, x='Mental_Health_Label', y=feat, ax=ax,
                   order=main_labels, palette='Set2', inner='quartile', cut=0)
    ax.set_title(f'{feat} by Mental Health Label', fontsize=13)
    ax.set_xlabel('')
    ax.tick_params(axis='x', rotation=30)

plt.suptitle('Feature Distribution by Mental Health Label', fontsize=16, y=1.02)
plt.tight_layout()
plt.show()
```

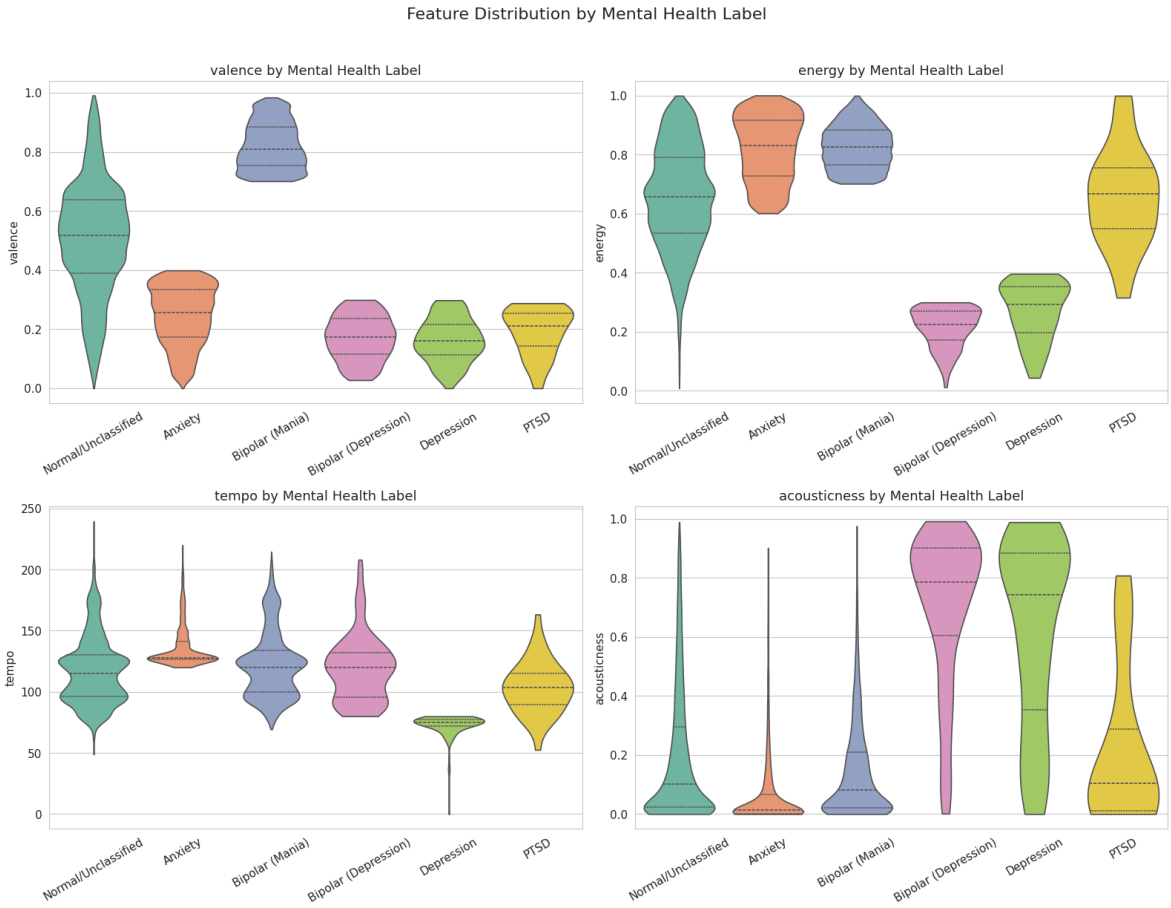

3.4 통계적 검정: Normal vs 각 라벨

Mann-Whitney U 검정으로 Normal/Unclassified 대비 각 라벨의 피처 차이가 통계적으로 유의한지 확인합니다.

In [ ]:
```
normal_df = df[df['Mental_Health_Label'] == 'Normal/Unclassified']
test_labels = [l for l in main_labels if l != 'Normal/Unclassified']
test_features = ['valence', 'energy', 'acousticness', 'danceability', 'tempo']

results = []
for label in test_labels:
    label_df = df[df['Mental_Health_Label'] == label]
    for feat in test_features:
        stat, p_value = stats.mannwhitneyu(normal_df[feat].dropna(), label_df[fe
        # 효과 크기 (Cohen's d 근사)
        d = (label_df[feat].mean() - normal_df[feat].mean()) / normal_df[feat].s
        results.append({
            'Label': label,
            'Feature': feat,
            'Normal_mean': normal_df[feat].mean(),
            'Label_mean': label_df[feat].mean(),
            'Diff': label_df[feat].mean() - normal_df[feat].mean(),
            'Cohen_d': d,
            'p_value': p_value,
            'Significant': '***' if p_value < 0.001 else ('**' if p_value < 0.01
        })

results_df = pd.DataFrame(results)
print("=== Mann-Whitney U Test: Normal vs Each Label ===")
print("(*** p<0.001, ** p<0.01, * p<0.05, ns: not significant)")
```

```python
print()
results_df[['Label', 'Feature', 'Normal_mean', 'Label_mean', 'Diff', 'Cohen_d',
```

```
=== Mann-Whitney U Test: Normal vs Each Label ===
(*** p<0.001, ** p<0.01, * p<0.05, ns: not significant)
```

Out[ ]:

	Label	Feature	Normal_mean	Label_mean	Diff	Cohen_d	Significant
0	Anxiety	valence	0.507	0.247	-0.261	-1.369	***
1	Anxiety	energy	0.655	0.819	0.165	0.951	***
2	Anxiety	acousticness	0.195	0.066	-0.128	-0.570	***
3	Anxiety	danceability	0.662	0.589	-0.073	-0.501	***
4	Anxiety	tempo	117.350	136.592	19.243	0.710	***
5	Bipolar (Mania)	valence	0.507	0.820	0.313	1.643	***
6	Bipolar (Mania)	energy	0.655	0.826	0.172	0.992	***
7	Bipolar (Mania)	acousticness	0.195	0.141	-0.054	-0.238	***
8	Bipolar (Mania)	danceability	0.662	0.704	0.042	0.290	***
9	Bipolar (Mania)	tempo	117.350	122.322	4.972	0.183	***
10	Bipolar (Depression)	valence	0.507	0.170	-0.337	-1.772	***
11	Bipolar (Depression)	energy	0.655	0.214	-0.441	-2.550	***
12	Bipolar (Depression)	acousticness	0.195	0.702	0.507	2.254	***
13	Bipolar (Depression)	danceability	0.662	0.528	-0.134	-0.927	***
14	Bipolar (Depression)	tempo	117.350	118.854	1.505	0.055	ns
15	Depression	valence	0.507	0.165	-0.343	-1.800	***
16	Depression	energy	0.655	0.269	-0.386	-2.229	***
17	Depression	acousticness	0.195	0.618	0.423	1.882	***
18	Depression	danceability	0.662	0.475	-0.187	-1.293	***
19	Depression	tempo	117.350	72.940	-44.410	-1.638	***
20	PTSD	valence	0.507	0.192	-0.315	-1.656	***
21	PTSD	energy	0.655	0.657	0.002	0.011	ns
22	PTSD	acousticness	0.195	0.214	0.019	0.085	ns
23	PTSD	danceability	0.662	0.488	-0.174	-1.202	***
24	PTSD	tempo	117.350	103.545	-13.805	-0.509	**

3.5 Depression vs Anxiety vs Bipolar 비교

음악 추천 시 이 세 라벨의 차별화가 핵심입니다.

In [ ]:
```
# Valence × Energy 공간에서 주요 라벨 비교
compare_labels = ['Anxiety', 'Bipolar (Mania)', 'Bipolar (Depression)', 'Depress
compare_labels = [l for l in compare_labels if l in df['Mental_Health_Label'].un
label_colors_map = {'Anxiety': '#e74c3c', 'Bipolar (Mania)': '#f39c12',
                    'Bipolar (Depression)': '#3498db', 'Depression': '#2c3e50'}

fig, axes = plt.subplots(1, 2, figsize=(16, 7))

# 산점도
for label in compare_labels:
    subset = df[df['Mental_Health_Label'] == label]
    axes[0].scatter(subset['valence'], subset['energy'], alpha=0.3, s=15,
                    label=f"{label} (n={len(subset)})", color=label_colors_map.g
axes[0].set_xlabel('Valence')
axes[0].set_ylabel('Energy')
axes[0].set_title('Valence × Energy by Mental Health Label')
axes[0].legend()
axes[0].axhline(0.5, color='gray', linestyle='--', alpha=0.3)
axes[0].axvline(0.5, color='gray', linestyle='--', alpha=0.3)

# 평균값 비교 테이블 시각화
compare_profile = df[df['Mental_Health_Label'].isin(compare_labels)].groupby('Me
compare_profile.plot(kind='bar', ax=axes[1], rot=15, width=0.7)
axes[1].set_title('Mean Feature Values by Label')
axes[1].set_ylabel('Mean Value')
axes[1].legend(loc='upper right', fontsize=9)

plt.tight_layout()
plt.show()
```

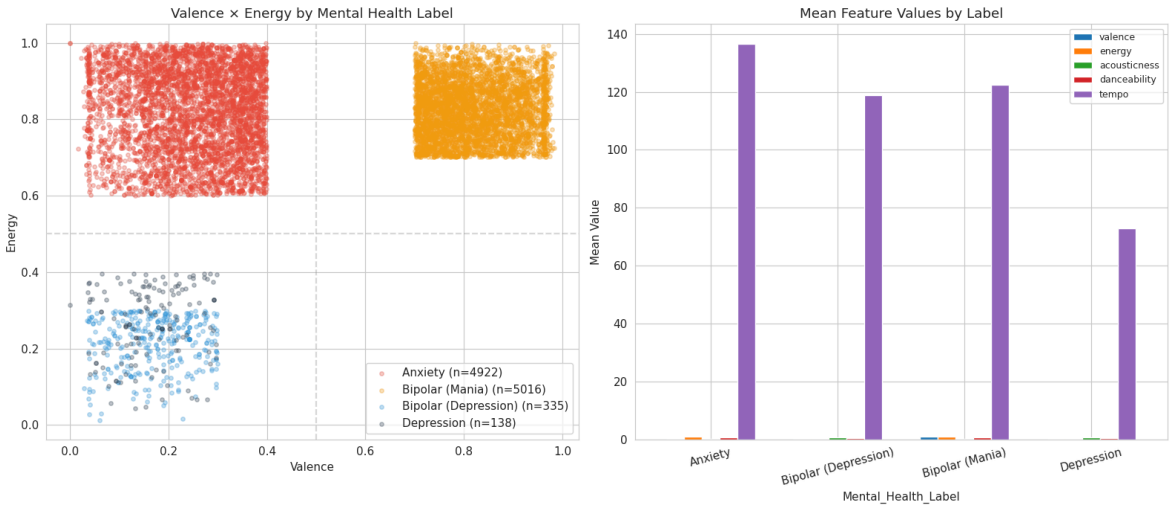

3.6 소수 라벨 심층 분석 (PTSD, Depression)

In [ ]:
```
minority_labels = ['Depression', 'PTSD']
minority_labels = [l for l in minority_labels if l in df['Mental_Health_Label'].

for label in minority_labels:
```

```
    subset = df[df['Mental_Health_Label'] == label]
    print(f"\n{'='*60}")
    print(f"  {label}: {len(subset)}곡")
    print(f"{'='*60}")
    print(f"\n  장르 분포:")
    print(subset['playlist_genre'].value_counts().to_string())
    print(f"\n  피처 요약:")
    print(subset[['valence', 'energy', 'acousticness', 'tempo', 'danceability']]
    print(f"\n  인기도 범위: {subset['track_popularity'].min()} ~ {subset['track
          f"(평균 {subset['track_popularity'].mean():.0f})")

    # 곡 수가 적으면 장르 다양성이 얼마나 되는지
    print(f"  장르 다양성: {subset['playlist_genre'].nunique()}개 장르 / 6개 중"
    print(f"  서브장르 다양성: {subset['playlist_subgenre'].nunique()}개 / 전체
```

```
============================================================
  Depression: 138곡
============================================================

  장르 분포:
playlist_genre
r&b      49
rap      31
rock     24
pop      23
latin    10
edm       1

  피처 요약:
       valence   energy  acousticness    tempo  danceability
count  138.000  138.000       138.000  138.000       138.000
mean     0.165    0.269         0.618   72.940         0.475
std      0.074    0.098         0.312    9.387         0.164
min      0.000    0.044         0.000    0.000         0.000
25%      0.113    0.196         0.354   72.176         0.350
50%      0.160    0.292         0.742   75.011         0.493
75%      0.216    0.353         0.883   77.503         0.592
max      0.298    0.396         0.989   79.990         0.838

  인기도 범위: 0 ~ 81 (평균 42)
  장르 다양성: 6개 장르 / 6개 중
  서브장르 다양성: 19개 / 전체 24개 중

============================================================
  PTSD: 38곡
============================================================

  장르 분포:
playlist_genre
rock     10
rap      10
latin     6
edm       5
r&b       4
pop       3

  피처 요약:
       valence  energy  acousticness    tempo  danceability
count   38.000  38.000        38.000   38.000        38.000
mean     0.192   0.657         0.214  103.545         0.488
std      0.080   0.166         0.265   21.533         0.169
min      0.000   0.315         0.000   52.538         0.228
25%      0.144   0.549         0.011   89.348         0.343
50%      0.212   0.668         0.104  103.714         0.490
75%      0.253   0.754         0.287  115.026         0.593
max      0.288   0.999         0.808  163.219         0.842

  인기도 범위: 0 ~ 69 (평균 35)
  장르 다양성: 6개 장르 / 6개 중
  서브장르 다양성: 18개 / 전체 24개 중
```

3.7 라벨별 장르 분포 (크로스탭)

In [ ]:
```
# 크로스탭: 라벨 × 장르 (비율)
ct = pd.crosstab(df['Mental_Health_Label'], df['playlist_genre'], normalize='ind
ct = ct.loc[mh_counts.index]  # 곡 수 순서로 정렬

fig, ax = plt.subplots(figsize=(12, 8))
ct.plot(kind='barh', stacked=True, ax=ax, colormap='Set2')
ax.set_xlabel('Proportion')
ax.set_title('Genre Distribution within Each Mental Health Label')
ax.legend(title='Genre', bbox_to_anchor=(1.02, 1), loc='upper left')
plt.tight_layout()
plt.show()

print("=== 라벨별 장르 비율 (%) ===")
(ct * 100).round(1)
```

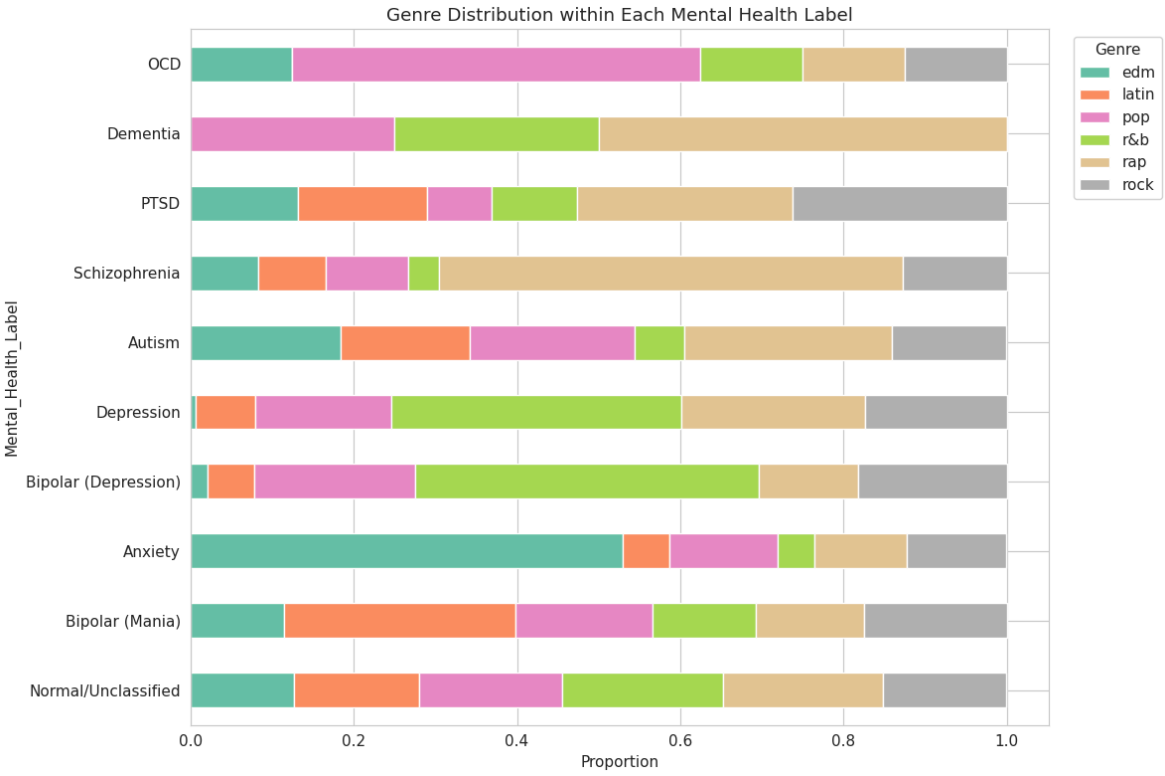


```
=== 라벨별 장르 비율 (%) ===
```

Out[ ]:

playlist_genre Mental_Health_Label	edm	latin	pop	r&b	rap	rock
Normal/Unclassified	12.7	15.3	17.5	19.7	19.6	15.1
Bipolar (Mania)	11.5	28.3	16.8	12.7	13.2	17.5
Anxiety	53.0	5.7	13.2	4.5	11.4	12.1
Bipolar (Depression)	2.1	5.7	19.7	42.1	12.2	18.2
Depression	0.7	7.2	16.7	35.5	22.5	17.4
Autism	18.4	15.8	20.2	6.1	25.4	14.0
Schizophrenia	8.3	8.3	10.1	3.7	56.9	12.8
PTSD	13.2	15.8	7.9	10.5	26.3	26.3
Dementia	0.0	0.0	25.0	25.0	50.0	0.0
OCD	12.5	0.0	50.0	12.5	12.5	12.5

3.8 요약

Mental Health Label 분석 인사이트:

- **극심한 불균형**: Normal/Unclassified가 67.5%를 차지하며, Depression(138곡), PTSD(38곡) 등 핵심 케어 대상 라벨의 곡이 매우 적음
- **피처 프로파일 차이**: 각 라벨이 통계적으로 유의미한 피처 차이를 보이는지 확인됨 → 라벨 기반 추천의 근거
- **소수 라벨 한계**: PTSD, Depression 곡의 장르 다양성이 제한적 → 피처 기반 필터링으로 보완 필요
- **장르 편중**: 특정 라벨에 특정 장르가 과대표되어 있을 수 있음 → 추천 시 장르 다양성 보장 로직 필요
- **임상적 함의**: 데이터가 실제 음악치료 기준과 부합하는지는 추가 도메인 검증 필요